

דוח איסוף נתוני סרטים

זיו נגר ותפארת בלוקה

1. החלטות שנלקחו בבניית סט הנתונים

- המרת שנת הסרט ואורך הסרט לטיפוס מסוג int64 כדי שידע להכיל גם ערכים חסרים.
- הכנת הטבלאות בנפרד לבדיקה, לפני חיבור הדאטה הסופית.
- הגדרת הסרטים לפי דירוג ופופולאריות.
- בניית פונקציה שמחפשת עמוד ויקיפדיה לפי שם הסרט והשנה שבה הוא יצא, ובניית פונקציה נוספת ששולפת מידע מטבלת הסרט בויקיפדיה.
- שמירת csv אחרי ההרצה של 5000 הסרטים לגיבוי בנוסף לשמירה הסופית הנדרשת.
- בבניית הפונקציות התייחסנו למספר פרמטרים:
 - קוד 429, שמנו לב שכאשר הזמן בין בקשה לבקשה מויקיפדיה הוא קצר מידי (בדקנו על פי שנייה אחת), האתר חוסם את הבקשות ולכן הארכנו את הזמן ל-5 שניות.
 - בדיקת קוד 200 על כל הסרטים כדי לוודא שאכן הפונקציה מוצאת את הסרט. במידה ואין קוד 200 או לא מוצא את עמוד הסרט, הגדרת הערכים בעמודות כ-NONE.
 - בחירת שפת Jason בתקשורת מול ויקיפדיה.
 - ראינו שכאשר ניסינו לחפש country ובויקיפדיה היו מספר מדינות, הוא לא הצליח לקרוא והחזיר NONE, לכן הגדרנו שיחזיר לפי המילה "country" כדי שיכניס גם "countries".
 - הגדרת המדינות שיופרדו בפסיקים לצורך הבנה וקריאות. לדוגמא הסרט: city of god (מופיע במחברת).
 - המידע נשלף מתוך טבלאות ה- Infobox של Wikipedia באמצעות BeautifulSoup. במהלך העבודה בוצע ניקוי של הערות שוליים ([1], [2]וכו') על מנת לקבל ערכים נקיים.

- חלק מהחיפושים ב־Wikipedia הובילו לDisambiguation Pages במקום לעמוד הסרט, לכן בוצע סינון של עמודים אלו ונוספה בדיקה שהעמוד שנבחר אכן מכיל את שם הסרט.

2. תיאור השדות של סט הנתונים:

Column Name	Type	Source	Description
tconst	String	IMDb	מזהה הסרט
primaryTitle	String	IMDb	השם המוכר של הסרט
start Year	Integer	IMDb	שנת יציאת הסרט לאקרנים
genres	Object (list of strings)	IMDb	ז'אנר הסרט (אקשן/דרמה וכו')
lead_actors_ids	Object (list of strings)	IMDb	רשימת 5 השחקנים המובילים של הסרט
runtimeMinutes	Integer	IMDb	משך הסרט בדקות
averageRating	Float	IMDb	ממוצע הדירוג לפי IMDb
numVotes	Integer	IMDb	מספר מדרגי הסרט
Language	String	Wikipedia	השפה הראשית בסרט
Country	String	Wikipedia	המדינה בה הסרט נוצר
budget	Object (Float)	Wikipedia	תקציב הפקת הסרט בממוצע (בדולרים)
BoxOffice	Object (Float)	Wikipedia	הכנסות גלובליות של הסרט בממוצע (בדולרים)
plot	String	OMDb	תקציר הסרט

3. מספר הסרטים שנאספו לסט הנתונים:

5000 סרטים.

4. אחוז ומספר הערכים החסרים בכל עמודה:

Column	Missing Values	Missing Percentage
tconst	0	0.00%
primaryTitle	0	0.00%
startYear	0	0.00%
genres	0	0.00%
lead_actors_ids	0	0.00%
runtimeMinutes	0	0.00%
averageRating	0	0.00%
numVotes	0	0.00%
Language	1,264	25.28%
Country	1,263	25.26%
budget	3,650	73.00%
BoxOffice	3,316	66.32%
plot	255	5.10%

- עבור שפה ומדינה קיבלנו שגיאה 403 כלומר חלק מדפי הויקיפדיה היו חסומים לגישה או שלא היה בהם מידע זה, לכן בסרטים אלו לא היה ניתן לשלוח נתונים.
- עבור שדות תקציב והכנסות, רוב המידע לא מופיע בדפי הויקיפדיה גם כאשר הדף עצמו קיים.
- תקצירי העלילה נשלפו מOMDb, האחוז של הערכים החסרים מתאים לסרטים שלא נמצאו במסד הנתונים של OMDb.